

2026 AI·SW중심대학 디지털 경진대회 : AI부문

너만 오면 오인 큐

목차

1. 데이터 분석

2. 모델 설계

3. 모델 분석

4. 앙상블 & 종류

5. 최적화

1. 데이터 분석

70,000

Train Data 샘플 수

9,429


고유 Session 수

14

Action Class

에이전트와 유저의 대화 데이터를 바탕으로 현재 유저 입력 프롬프트에 대한
에이전트 Action을 예측하는 문제

1. 데이터 분석



- **탐색 조회** **42.9%**
list_directory, glob_pattern, grep_search, read_file, web_search
- **파일 변경** **25%**
edit_file, write_file, apply_patch
- **실행 검증** **17%**
run_bash, run_tests, lint_or_typecheck
- **질문 계획** **7.7%**
ask_user, plan_task
- **단순 응답** **7.4%**
respond_only

탐색,조회,파일 변경 이 60% 이상을 차지하는 불균형 분포


1. 데이터 분석

직전 action에서 현재 action으로 이어지는 전이확률 분석



일부 action 쌍에서 높은 조건부 전이 확률을 관측했으며 이를 핵심 피처로 이용

2. 모델 설계



3개의 핵심 Context (유저 발화, 과거 정보, 세션 정보)를 결합한
다중 맥락 인지형 Action class 분류 구조 설계

2. 모델 설계

왜 mmBERT-small 인가?

최신 아키텍처

- 8K Sequence length 지원
- 다국어 지원
- 2025년 공개된 최신 다국어 인코더
- Modern BERT 기반

대규모 사전학습

- 3T 토큰 규모의 사전학습 데이터
- 코딩 관련 데이터 포함 학습

경량 구조

- 140M 크기의 small 모델
- 약 42M의 비임베딩 파라미터

2. 모델 설계

● 유저 발화 <TURN_N> <CUR> <PREV_USER>

현재 유저의 프롬프트와 직전 프롬프트, 현재 turn 정보를 직접적으로 담는 블록

● 과거 정보 <LAST_ACTION> <LAST_RESULT> <LAST_ARGS> <PREV_ACTION>
<ACTION_SEQ>

직전 에이전트의 action과 그 결과, args 그리고 지금까지의 action history를 담는 블록

● 세션 정보 <OPEN_FILES> <PROMPT_FEATURE> <SESSION_FEATURE>

현재 세션의 메타 데이터를 포함하는 블록

2. 모델 설계

실제 입력 예시

<TURN_4>

<CUR> 이제 parser 테스트만 한번 돌려봐 가볍게 </CUR>

<PREV_USER> command이 sh -c로 감싸는구나... 이거 인젝션 표면이네. 실제 동작 한번만 짚어보자

</PREV_USER>

[SEP]

<LAST_ACTION> <A_RUN_TESTS> </LAST_ACTION>

<LAST_RESULT> <RESULT_FAILED> <HAS_TEST_FAIL> FAIL: 191 tests failing </LAST_RESULT>

<LAST_ARGS> path=tests/Button.test.tsx ext=tsx pattern=none cmd=<CMD_UNKNOWN>

</LAST_ARGS>

<PREV_ACTION> <A_EDIT_FILE> </PREV_ACTION>

<ACTION_SEQ> <A_READ_FILE> <A_EDIT_FILE> <A_RUN_TESTS> </ACTION_SEQ>

<OPEN_FILES> package.json </OPEN_FILES>

<PROMPT_FEATURE> <P_WORD_RUN> <P_WORD_TEST> </PROMPT_FEATURE>

<SESSION_FEATURE> <DIRTY_TRUE> <CI_FAILED> <OPEN_SOME> turn=4 history=6 actions=3

loc=58700 budget=70033 primary_lang=ts open_exts=json </SESSION_FEATURE>

2. 모델 설계

Weighted
Cross-Entropy

learning rate
tuning

Session 단위로
데이터 분할

Leaderboard macro-F1 **0.78** 달성

28346 **submit.zip**
[Add memo](#)


2026-07-06 21:16:13 0.7830539834 ⌚ 1m 29s

기존 baseline (TF-IDF)대비 **0.347** 상승.

24638 **baseline_submit.zip**
[Add memo](#)

2026-07-01 15:19:16 0.4357635462 ⌚ 4s

3. 모델 분석



모델 출력의 혼동행렬 분석

group1

group2

group3

list_directory
glob_pattern
grep_search
read_file


web_search
plan_task
ask_user

run_bash
run_tests
lint_or_typecheck

모델이 대분류는 잘하고 있지만
대분류내 세부분류에 약함

3. 모델 분석

추가 분류를 통한 해결시도



1. BERT가 충분한 정보를 담고있기에, 2차모델이 그룹내 분류를 못함
2. 분류기의 표현력이 아닌, 경계사이의 혼동에 집중

3. 모델 분석

mmbert의 서로다른 시드 3개의 Group1 부분 혼동행렬의 모습


130	17	21	46
40	168	24	32
62	25	310	98
86	17	80	277

148	15	12	41
45	168	16	35
64	32	251	145
92	17	41	312

141	8	18	49
34	170	18	41
65	19	291	120
76	29	49	304

시드(초기값) 초기화를 통해서도 서로 다른 혼동행렬을 얻을 수 있음

3. 모델 분석




단일모델대비 앙상블 성능 향상. 다양성이 실제로 작동했다는 증거

3. 모델 분석

prompt :


이거 metro 설정 좀 봐야 할 거 같은데 어떤 파일 건드려야 되는지 모르겠어.
우리 워크스페이스에 metro 설정 파일 어디 있어?



3. 모델 분석


prompt :

이거 metro 설정 좀 봐야 할 거 같은데 어떤 파일 건드려야 되는지 모르겠어.
우리 워크스페이스에 metro 설정 파일 어디 있어?



3. 모델 분석

서로 다른 학습률을 갖는 학생모델 5개를 증류. 이후, 다양성을 위한 학생 앙상블




$$teacher(x) = \sum_i w_i softmax(z_i(x))$$

$$\mathcal{L}_{student} = (1 - \alpha)CE(y, student(x)) + \alpha T^2 \cdot KL(teacher^T(x) || student^T(x))$$

TOP5 모델의 예측분포를 추가 학습신호로 사용하여 학습


4. 앙상블 & 종류

1. TAPT – 과제 적응 사전학습



4. 앙상블 & 종류

2. R-Drop – 드롭아웃 일관성 정규화




4. 앙상블 & 종류

3. long_ctx 확장

	베이스라인	long_ctx 확장
결과 이력	LAST_RESULT 최근 1개	HISTORY_RESULTS 최근 6개
열린 파일 목록	OPEN_FILES_COUNT=8, MAX_OPEN_FILES_CHARS=360	OPEN_FILES_COUNT=24, MAX_OPEN_FILES_CHARS=1200

기존 모델과 long_ctx 변형 모델을 앙상블하여 서로 다른 관점을 이용해 보완

4. 앙상블 & 종류




기존 베이스 모델 앙상블

TAPT, R-drop

0.74%p 점수 상승

4. 앙상블 & 종류


LB 리더보드 성능비교



4. 앙상블 & 증류

최종 모델 구성

mmbert




* 0.325

Long_ctx

증류 모델




* 0.675




5. 최적화

3개 모델 앙상블



700MB
3m 25s



8개 모델 앙상블




1,840MB
10m ↑↑

앙상블 모델 개수가 늘어나면 성능도 늘어난다.
그러나 용량/시간 문제로 인해 많은 모델을 담지 못함

5. 최적화


Delta compression



1. 모델을 동일 구조를 갖는 것끼리 묶음
2. 기준 모델 선정, 각 모델의 가중치를 기준모델의 차로 표현
3. Zip 압축(delta ≈ 0 이므로 압축 성능 상승)

5. 최적화


Progressive Early-Exit



가장 영향력 높은 모델



확정된 class 예측에 대해서는 다른모델 추론 X



불확실한 class 예측에 대해선,
다른모델 추론 O


$\text{margin (1 위 클래스 - 2 위 클래스 확률차)} > \text{remaining weight (남은 모델 가중치 합)}$

→ 최종 클래스 수학적으로 확정

5. 최적화

길이 기반 동적 배치

 데이터 단위



샘플을 토큰 길이 내림차순으로 정렬한 뒤, 토큰 예산 기준으로 배치를 구성
=> 패딩 낭비와 GPU step 수를 동시에 줄임

5. 최적화

GPU 입력 캐시 · CPU/GPU 병렬 처리

CPU

모델1 delta 복원

모델2 delta 복원

모델3 delta 복원

모델4 delta 복원

GPU

모델1 추론

모델2 추론

모델3 추론

여러 모델이 공유하는 패딩 입력 텐서를 GPU에 미리 올려,
모델마다 동일 입력을 CPU→GPU로 반복 복사하는 비용 제거

5. 최적화

delta compression

용량 압축
 $230MB * 8$
 $\approx 1.8GB \geq 1GB$
 $\Rightarrow 887MB$

Progressive Early-Exit

길이기반 동적 배치


CPU/GPU 병렬처리

추론시간
 $90s * 8$
 $= 12m \geq 10m$
 $\Rightarrow 5m 14s$

감사합니다

Q & A

Base 모델 Ablation study



Action seq 정보 제거 -> 점수 큰 폭으로 하락 관측

분포 기반 증류

